Relatório Teórico – Data Warehouse & Business Intelligence

Tema: Análise de Género no Ensino Superior Europeu (2013–2023)

Unidade Curricular: Data Warehouse e Business Intellinge

Ano letivo: 2025/2026

Trabalho realizado por: Pedro Ferreira

Curso: Análise de dados em gestão de informação

Conteúdo

KPIs Globais – Estado Geral da Paridade 4
KPIs Comparativos – Onde Estão os Desvios? 4
KPIs Temporais – Como Evoluiu a Paridade? 4
Normalização de Nomes de Colunas e Valores 9
Tratamento de Valores em Falta 9
Colunas Derivadas e Medidas 9
Modelo Conceptual: 10
Visão Geral (KPIs Principais) 13
Análise Comparativa por País e Categoria 13
Ranking Horizontal – IPG por País 14
Análise por Ciclo de Estudo 15
..... 15
Análise por Área de Educação 15
Tendências Temporais (Análise Comparativa e Evolutiva) Gráfico de Barras Empilhadas – % Mulheres e % Homens por Ano 16
Segmentadores, Filtros e Interatividade 16
Design e Apresentação Visual 17
Principais Resultados Obtidos 17
A) Países com maior impacto nos totais europeus 17
Equilibrar presença masculina em áreas como Educação e Saúde 18
Como implementar: 18
Monitorização anual contínua 18
Como implementar: 18

Parte 1 – Componente Teórica

Introdução

A *EuroEdu Analytics Center* é uma entidade fictícia criada no âmbito deste projeto, representando um centro europeu especializado na recolha, gestão e análise de dados sobre educação e igualdade social. Trata-se de uma organização independente e sem fins lucrativos, vocacionada para a produção de análises estatísticas que apoiem decisões informadas no setor educativo.

Composta por uma equipa multidisciplinar de analistas de dados, estatísticos e especialistas em sistemas de informação, a EuroEdu Analytics beneficia de acesso a bases de dados públicas e colaborações académicas que reforçam a fiabilidade das suas análises.

O ensino superior europeu constitui uma das áreas prioritárias de estudo, dada a importância crescente de compreender como se distribui a participação de homens e mulheres por países, ciclos de estudo e áreas de formação. Apesar da abrangência e qualidade da base de dados da PORDATA, a sua organização dispersa por múltiplas categorias dificulta análises comparativas imediatas.

Neste contexto, a implementação de uma solução de *Data Warehouse* (DW) aliada a um sistema de *Business Intelligence* (BI) permite consolidar, normalizar e explorar os dados de forma sistemática e interativa.

O presente relatório descreve todas as fases do projeto — desde a definição conceptual até à construção prática do modelo — com foco na análise da paridade de género no ensino superior europeu no período de 2013 a 2023.

Análise de Requisitos

A análise de requisitos é o ponto de partida fundamental para garantir que a solução de BI responde efetivamente às necessidades da organização.

No caso da *EuroEdu Analytics Center* o objetivo é obter uma visão clara, estruturada e comparável da distribuição de género no ensino superior europeu, permitindo identificar padrões, assimetrias e tendências temporais com base em dados concretos.

Objetivo de Negócio

O principal objetivo consiste em criar uma solução analítica capaz de:

- Avaliar o grau de paridade de género no ensino superior europeu;
- Comparar realidades entre países, áreas de formação e ciclos de estudo;
- Identificar tendências de evolução entre 2013 e 2023;
- Apoiar a definição de políticas educativas mais informadas e equitativas.

A solução deve ser flexível, adaptando-se às necessidades de diferentes perfis de utilizador, tanto para análises de alto nível como para consultas mais detalhadas.

Indicadores-Chave de Desempenho (KPIs)

Foram definidos KPIs agrupados em quatro categorias principais, com o intuito de responder às questões centrais da análise:

KPIs Globais – Estado Geral da Paridade

Estes indicadores oferecem uma visão geral da distribuição de género:

- Total de Alunos
- Total de Homens
- Total de Mulheres
- Percentagem de Homens
- Percentagem de Mulheres
- Diferença Percentual entre Géneros

Permitem avaliar rapidamente se existe equilíbrio (aproximado de 50/50) ou se há desvios relevantes.

KPIs Comparativos – Onde Estão os Desvios?

Estes indicadores detalham a distribuição por categorias específicas:

- Percentagem de Homens/Mulheres por País
- Percentagem por Ciclo de Estudo
- Percentagem por Área de Educação

A análise ajuda a distinguir se as desigualdades são:

- Culturais (associadas ao país),
- Estruturais (relacionadas com o nível de ensino),
- Vocacionais (ligadas às áreas de formação).

KPIs Temporais – Como Evoluiu a Paridade?

Indicadores que analisam a evolução ao longo da década:

- Variação anual da percentagem de mulheres
- Variação anual da percentagem de homens

Permitem observar tendências como crescimento, estabilidade ou retrocessos.

KPIs de Contributo – Quem Pesa Mais no Total Europeu?

Indicadores que avaliam o peso relativo de cada país no panorama europeu:

Contributo (%) de Homens por País
Contributo (%) de Mulheres por País

São úteis para identificar países com maior influência estatística devido à sua dimensão populacional.

Stakeholders

O sistema foi desenhado para responder às necessidades de vários perfis de utilizador:

Direção: requer indicadores de visão global e comparações estratégicas;
Equipa de Investigação Estatística: necessita de análises detalhadas e segmentadas;
Equipa de BI: responsável pelos processos ETL, validação e performance do sistema;
Analistas Finais: utilizam dashboards interativos para produzir relatórios e recomendações.

A identificação clara destes perfis permitiu adequar o nível de detalhe dos KPIs à realidade operacional de cada grupo.

Modelação Conceptual e Lógica

Esquema Estrela (Star Schema)

O modelo dimensional adotado segue um **esquema estrela**, por ser o mais adequado a sistemas de BI — simples, eficiente e de fácil interpretação, especialmente em ferramentas como o Power BI.

Embora na prática se tenha usado uma única tabela consolidada (uma vez que os dados da PORDATA já vêm desnormalizados), o modelo conceptual mantém a estrutura formal de um DW: uma **tabela de factos** central e várias **dimensões** que a contextualizam.

Tabela de Factos

A tabela Fact_Ensino_Superior inclui as seguintes colunas:

- Ano
- País
- Género
- Ciclo_de_Estudo
- Área_de_Educação
- Número_de_Alunos

Cada registo representa uma combinação única destas dimensões, com granularidade definida como:

Ano × País × Género × Ciclo de Estudo × Área de Educação

Dimensões Conceptuais

O modelo define cinco dimensões conceptuais (não materializadas como tabelas separadas):

País – lista dos países europeus considerados;
Ano – de 2013 a 2023;
Género – Masculino e Feminino;
Ciclo_de_Estudo – Ciclo Curto, Licenciatura, Mestrado, Doutoramento;
Área_de_Educação – conforme categorias da PORDATA.

Estas dimensões compõem a base teórica do modelo, alinhada com as boas práticas de modelação em BI.

Medidas DAX

Optou-se por utilizar **medidas DAX** em vez de colunas calculadas, por três razões principais:

As medidas ajustam-se dinamicamente aos filtros aplicados;
Evitam o aumento do tamanho do modelo;
Mantêm o relatório mais leve e organizado.

Entre as principais medidas, destacam-se:

- Total Alunos
- Total Homens
- Total Mulheres
- % Homens
- % Mulheres
- Diferença Percentual entre Géneros
- IPG (Índice de Paridade de Género)

Processos ETL

O processo de **Extração, Transformação e Carregamento (ETL)** foi realizado em duas etapas complementares: no **Excel** e no **Power BI (Power Query)**, assegurando a preparação adequada dos dados para o modelo dimensional.

Extração

Os dados foram obtidos da **PORDATA** em formato CSV/Excel, contendo registos agregados por ano, país, género, ciclo de estudo, área de educação e número de alunos inscritos.

Transformação

Fase 1 – Excel

- Conversão do CSV para Tabela; usando a função dados e clicar em obter dados.
- Normalização de cabeçalhos (ex.: “Ciclo de estudo” → “Ciclo_de_Estudo”);
- Filtrar manualmente os valores em branco;
- Verificação de tipos de dados;
- Remoção de colunas irrelevantes ou vazias.

Fase 2 – Power Query (Power Bi)

- Confirmação dos tipos de dados;
- Criar uma medida DAX por causa de não ter filtrado os valores em branco do Total de alunos criando uma medida Total de alunos sem a soma dos valores em branco;
- Uniformização textual para consistência em filtros;
- Eliminação de duplicados.

Decisão-chave: todos os cálculos foram implementados via **medidas DAX**, evitando a criação de colunas derivadas.

Carregamento

A tabela final, limpa e estruturada, foi carregada no Power BI. Seguiram-se:

- Criação das medidas;
- Validação dos filtros e interações visuais;
- Preparação dos dashboards.

Governança e Segurança dos Dados

Embora os dados sejam públicos e agregados, a implementação respeitou princípios essenciais de **governação de dados**:

Controlo de Acessos (RBAC)

Através do Power BI Service, seriam definidos níveis de acesso como:

Administrador – gestão do modelo e atualizações;
Editor – criação de relatórios;
Leitor – consulta de dashboards.

Qualidade e Rastreabilidade

- Documentação dos passos no Power Query;
- Nomenclatura consistente em colunas e medidas;
- Validação cruzada com os dados originais da PORDATA;
- Verificação e atualização anual.

Evolução do Modelo

O modelo está preparado para:

- Adição de novos anos;
- Criação de novas medidas DAX;
- Integração de novas áreas de estudo.

Conclusão (Teórica)

A solução desenvolvida permitiu transformar dados dispersos da PORDATA numa estrutura organizada, validando na prática os conceitos abordados na unidade curricular de DW e BI.

O modelo conceptual em **esquema estrela** revelou-se eficaz e adaptado aos objetivos analíticos, com granularidade suficiente para comparações detalhadas. O uso exclusivo de **medidas DAX** manteve o modelo leve e responsivo.

Do ponto de vista técnico, o processo ETL reforçou a importância da limpeza, normalização e validação de dados antes do carregamento. Mesmo com uma fonte pública estruturada, a preparação cuidadosa foi essencial para garantir qualidade analítica.

Através dos dashboards criados, foi possível analisar diferenças de género ao longo do tempo e entre países, ciclos de estudo e áreas formativas. Os KPIs permitiram leituras claras e fundamentadas, oferecendo uma base sólida para relatórios e recomendações.

Parte 2 – Componente Prática

Seleção do Tema e da Fonte de Dados

A componente prática deste projeto consistiu na implementação da solução de DW/BI descrita anteriormente, aplicada ao tema **"Análise de Género no Ensino Superior Europeu (2013–2023)"**. Esta análise foi conduzida no contexto da organização fictícia *EuroEdu Analytics Center*, que utiliza este sistema para monitorizar a paridade de género no ensino superior e gerar estudos comparativos entre países, ciclos de estudo e áreas formativas.

A fonte de dados escolhida foi a **PORDATA**, em formato CSV/Excel. Estes dados agregam informações por **Ano**, **País**, **Género**, **Ciclo de Estudo**, **Área de Educação** e **Número de Alunos inscritos**. A sua utilização assegura fiabilidade, consistência e comparabilidade entre os países europeus, cumprindo os critérios de qualidade exigidos para um projeto de BI assente em dados públicos.

Preparação e Limpeza dos Dados (ETL)

O processo de **Extração, Transformação e Carregamento (ETL)** foi conduzido em duas fases principais: a primeira no **Excel**, e a segunda no **Power BI (Power Query)**. O objetivo foi garantir que os dados estivessem devidamente limpos, estruturados e prontos para a criação do modelo dimensional.

Normalização de Nomes de Colunas e Valores

Após a importação do ficheiro CSV no Excel, a informação foi convertida para uma **tabela estruturada**, o que facilitou a aplicação de transformações iniciais.

Foram realizadas as seguintes ações:

- Normalização dos cabeçalhos (ex.: “Ciclo de estudo” → “Ciclo_de_Estudo”);
- Uniformização de maiúsculas/minúsculas e remoção de espaços em branco;
- Verificação e correção dos tipos de dados:

Ano e Número de Alunos definidos como **números inteiros**; País, Género, Ciclo e Área de Educação mantidos como **texto**.
Este processo garantiu que, ao importar os dados para o Power BI, os campos fossem corretamente interpretados, permitindo a correta aplicação de filtros, segmentadores e medidas.

Tratamento de Valores em Falta

A coluna **Número de Alunos** apresentava alguns valores em branco/nulos para determinadas combinações de país, ano, ciclo e área.

Em vez de eliminar essas linhas — o que poderia comprometer a integridade analítica —, optou-se por **gerir os valores nulos ao nível das medidas DAX**. Foi criada uma medida de **Total de Alunos** que soma apenas os registos válidos, ignorando os valores em falta.

Com esta abordagem:

- Evitou-se a exclusão de dados potencialmente úteis;
- Garantiu-se que os gráficos e KPIs apresentassem apenas dados completos;
- Manteve-se a simplicidade e leveza do modelo.

Colunas Derivadas e Medidas

Apesar do guião do projeto prever a criação de **colunas derivadas**, decidiu-se não as implementar, uma vez que todas as necessidades analíticas envolviam **cálculos agregados** (percentagens, rácios, diferenças).

Assim, toda a lógica de cálculo foi implementada através de **medidas DAX**, o que trouxe várias vantagens:

- Maior flexibilidade (ajustam-se dinamicamente aos filtros aplicados);
- Redução do volume de dados no modelo;
- Organização mais clara e eficiente dos relatórios.

As principais medidas criadas foram:

- Total Homens
- Total Mulheres
- % Homens
- % Mulheres
- Diferença Absoluta entre Géneros
- Diferença Percentual entre Géneros
- IPG – Índice de Paridade de Género

Modelação Dimensional

A estrutura do modelo seguiu os princípios do **esquema estrela**, conforme definido na parte teórica. Contudo, tendo em conta que os dados da PORDATA já vêm desnormalizados, optou-se por uma **implementação prática com uma única tabela consolidada**.

Modelo Conceptual:

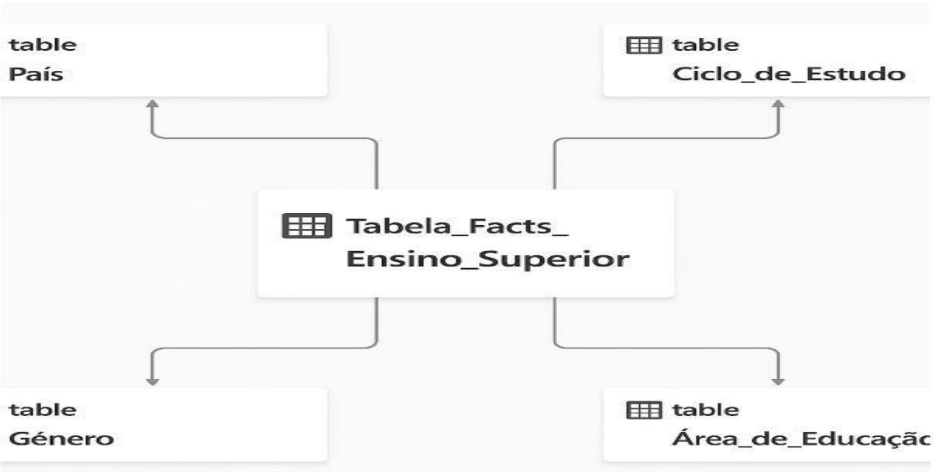

O modelo conceptual é composto por:

Uma **tabela de factos**: Fact_Ensino_Superior;
Cinco **dimensões teóricas**: País, Ano, Género, Ciclo de Estudo e Área de Educação.

Este modelo permite cruzar diversas perspetivas analíticas (temporal, geográfica, académica e de género) sobre a métrica central: Número de Alunos.

Implementação Prática

Na prática, os dados foram carregados numa única tabela designada por Fact_Ensino_Superior, contendo as seguintes colunas:

- Ano
- Nome do País (Europa)
- Género
- Ciclo_de_Estudo
- Área_de_Educação
- Número_de_Alunos

Cada linha corresponde a uma combinação única destes campos — respeitando a granularidade definida. Esta abordagem simplifica o modelo sem sacrificar a capacidade analítica.

Embora as dimensões não estejam fisicamente separadas, a **estrutura lógica de um esquema estrela mantém-se válida**.

Relações e integridade

Dado que foi utilizada uma única tabela consolidada, não foi necessário criar relações PK/FK no modelo do Power BI. Ainda assim, foi verificado que não existiam duplicações para a combinação Ano × País × Género × Ciclo × Área e que as categorias textuais eram consistentes. Assim, a integridade do modelo é garantida pela própria estrutura dos dados e pelo processo de ETL, que assegura que cada linha corresponde a uma observação distinta.

Construção do Data Model no Power BI

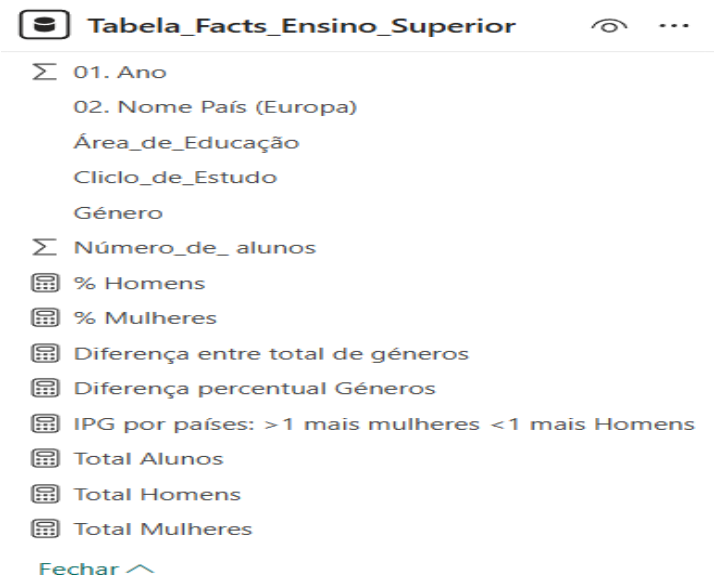

A construção do modelo no Power BI passou por três etapas principais: o carregamento da tabela tratada, a verificação da sua integridade e a criação

das medidas DAX que suportam os indicadores definidos na parte teórica do projeto.

Carregamento da Tabela Tratada

A tabela final, previamente limpa no Excel e no Power Query, foi carregada para o Power BI com o nome **Tabela_Facts_Ensino_Superior**. Nesta fase, foram novamente verificados os tipos de dados de cada coluna: os campos "Ano" e "Número de Alunos" foram configurados como numéricos, enquanto os campos "País", "Género", "Ciclo_de_Estudo" e "Área_de_Educação" foram definidos como texto. Esta configuração foi essencial para garantir que os filtros, segmentações e agregações funcionassem corretamente nas visualizações.

Verificação da Integridade do Modelo

Apesar de o modelo prático recorrer apenas a uma tabela consolidada, foram realizadas validações importantes para garantir a sua integridade. Verificou-se, por exemplo, que não existiam valores nulos nas colunas essenciais — especialmente na coluna "Número de Alunos", que foi adicionalmente controlada pelas medidas criadas em DAX. Confirmou-se ainda que não havia duplicações na granularidade definida (com base em Ano, País, Género, Ciclo e Área), e que os filtros aplicados nos relatórios produziam resultados consistentes. Com estas validações, assegurou-se que o modelo estava pronto para suportar análises fiáveis.

Medidas e cálculos DAX

Com a tabela validada, foram criadas as medidas DAX necessárias para operacionalizar os KPIs definidos na parte teórica. Entre as principais medidas encontram-se: Total Alunos, Total Homens, Total Mulheres, Percentagem de Homens, Percentagem de Mulheres, Diferença Absoluta de Género, Diferença Percentual de Género e IPG (Índice de Paridade de Género). Estas medidas alimentam os cartões de indicadores, os gráficos comparativos e as análises temporais, permitindo explorar o mesmo conjunto de dados sob diferentes perspetivas de forma dinâmica. Aqui estão os cálculos das medidas.

Total Alunos = [Total Mulheres] + [Total Homens]

Total de Homens=CALCULATE(SUM([Número_de_alunos]),'Tabela_Facts_Ensino_Sup erior'[género]= "Homens")

Total Mulheres = CALCULATE (SUM ([Número_de_ alunos]),'Tabela_Facts_Ensino_Superior'[género] = "Mulheres")

IPG por países: >1 mais mulheres <1 mais Homens = DIVIDE ([Total Mulheres], [Total Homens])

% Homens = DIVIDE ([Total Homens], [Total Alunos])

% Mulheres = DIVIDE ([Total Mulheres], [Total Alunos])

Diferença entre total de géneros = ABS ([Total Mulheres] - [Total Homens])

Diferença percentual Géneros = ABS ([% Mulheres] - [% Homens])

IPG por países: >1 mais mulheres <1 mais Homens = DIVIDE ([Total Mulheres], [Total Homens])

Desenvolvimento do Dashboard

Visão Geral (KPIs Principais)

KPIs apresentados: Interpretação Global:

A página inicial apresenta os principais indicadores:

- Maior número de mulheres inscritas no ensino superior europeu;
- Estabilidade nas proporções (cerca de 54% mulheres e 46% homens).
- Verifica se 179,39 milhões de Homens no ensino superior de 2013 a 2023, mas de mulheres são 211,06 milhões no total são 390,46 milhões de alunos no ensino superior nos anos estudados.
- A diferença percentual entre os dois géneros é de 0,08%.

Esta visão geral funciona como ponto de entrada para a análise, permitindo uma compreensão rápida do panorama global.

Análise Comparativa por País e Categoria

Esta página aprofunda a análise comparativa entre os países europeus, sendo composta por: **Mapa Interativo – IPG por País**

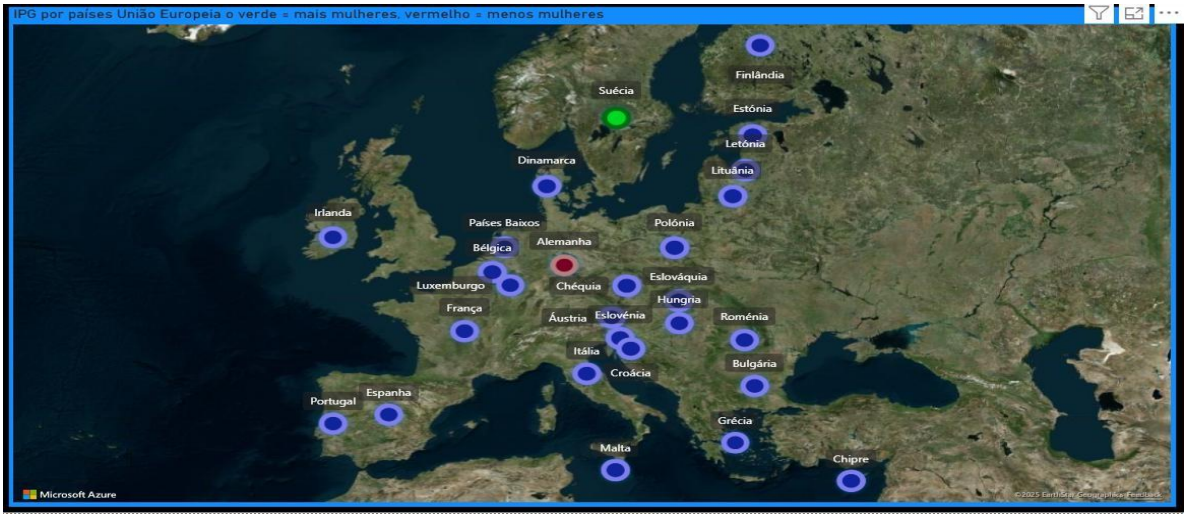

O mapa mostra a distribuição geográfica do IPG na Europa: Círculo **verde** = país com mais mulheres, Círculo **vermelho** = país com mais homens, Círculos **azuis** = valores no meio entre os máximos.

A visualização permite identificar padrões geográficos:

Que a Suécia é o país com mais mulheres inscritas no ensino superior nestes anos em estudo e a Alemanha é aquele com mais Homens logo com menos mulheres no ensino superior durante estes 10 anos estudados.

Ranking Horizontal – IPG por País

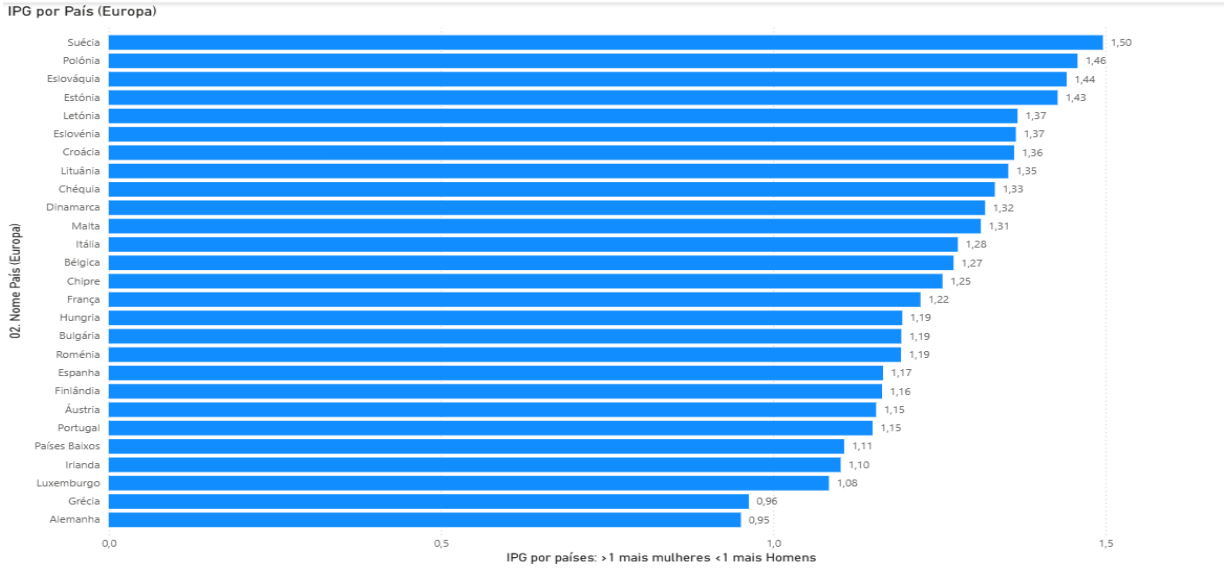

Este gráfico classifica os países do valor mais elevado para o mais baixo:

Suécia (1,50) é o país com maior
predominância feminina
Polónia, Eslováquia, Estónia e Letónia seguem com valores elevados
Alemanha (0,95) e Grécia (0,96) são os únicos abaixo da paridade

O ranking complementa o mapa ao permitir comparar países rapidamente.

Análise por Ciclo de Estudo

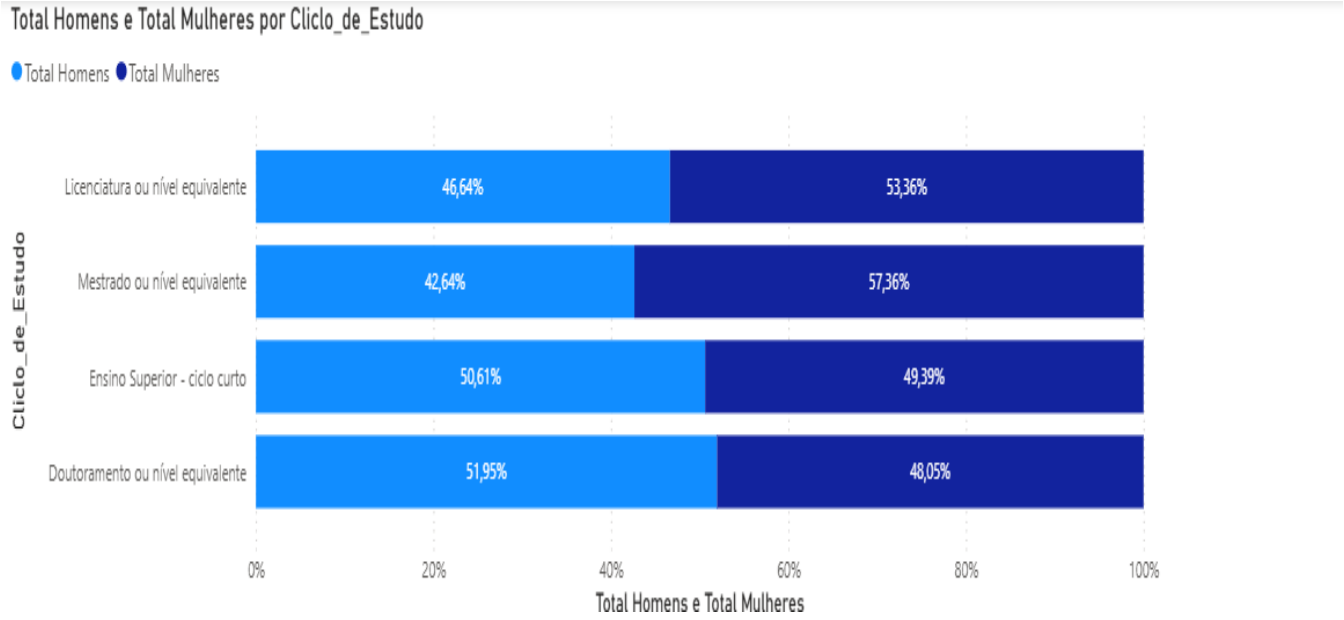

O gráfico de barras empilhadas mostra a distribuição de Homens e Mulheres por Ciclo: **Licenciatura e Mestrado** tem maiores proporções de mulheres, **Ciclo curto** tem quase equilíbrio absoluto, **Doutoramento** tem ligeira predominância masculina

Esta informação permite identificar diferenças estruturais na progressão académica. Que não são muito desequilibrados os valores em percentagem em ambas, embora no mestrado se note a maior discrepância.

Análise por Área de Educação

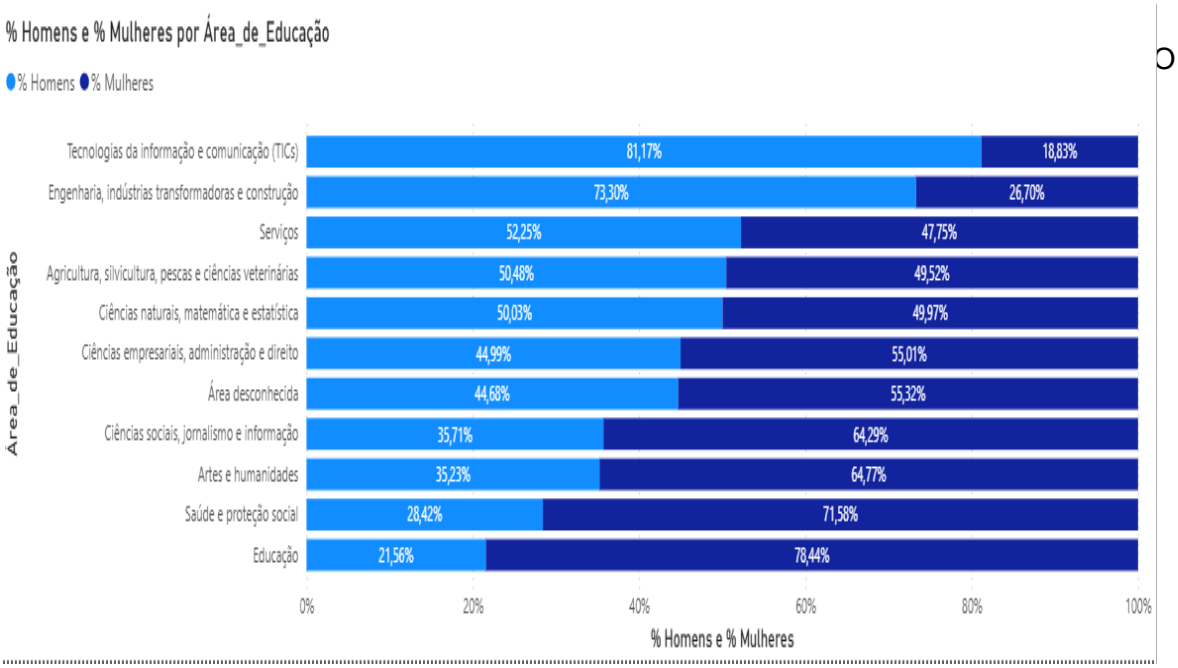

gráfico horizontal apresenta a % de Homens e % de Mulheres em cada área:

Mais mulheres:
Educação (78,44%), Saúde (71,58%), Artes e Humanidades (64,77%), Ciências Sociais (64,29%)
Mais homens:
TIC (81,17%), Engenharia (73,30%), Ciências Naturais (50,03%)

Esta página mostra onde se verificam desigualdades vocacionais, revelando assimetrias significativas entre áreas de estudo.

Tendências Temporais (Análise Comparativa e Evolutiva) Gráfico de Barras Empilhadas – % Mulheres e % Homens por Ano

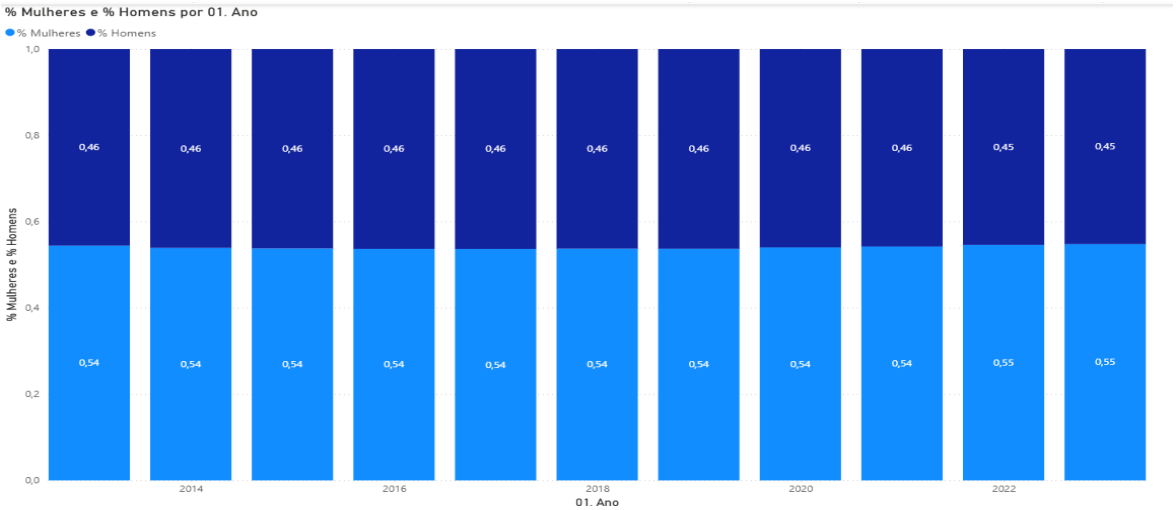

A visualização mostra que: a proporção entre géneros se mantém **estável** ao longo do tempo, as mulheres representam de forma consistente entre 54% e 55%, os homens oscilam entre 45% e 46%.

Embora não existam grandes variações anuais, o gráfico confirma a tendência de estabilidade e permite verificar alterações subtis, como o aumento ligeiro da percentagem feminina nos últimos anos.

Segmentadores, Filtros e Interatividade

Todos os gráficos beneficiam da interatividade nativa do Power BI: segmentadores por **Ano, País, Género, Ciclo e Área de Educação**, filtros que ajustam automaticamente todos os KPIs e gráficos, possibilidade de drill-down e drill-through nas visualizações e destaque automático de países e categorias ao selecionar elementos no mapa ou ranking.

Esta interatividade permite ao utilizador “navegar” nos dados e obter insights mais específicos consoante a necessidade.

Design e Apresentação Visual

O design seguiu uma linha simples e profissional: Palete de cores coerente (azul, verde e cinza), Títulos claros e informativos, Legendas concisas e consistentes, Mapas com destaque visual (Azure Maps), Layout equilibrado entre KPIs, gráficos horizontais e mapas

A página está organizada para facilitar a leitura e evitar sobrecarga visual, garantindo que o utilizador identifica rapidamente as tendências mais relevantes.

Interpretação e Conclusões

Principais Resultados Obtidos

A análise global revela que o ensino superior europeu apresenta uma distribuição de género relativamente equilibrada, com uma ligeira predominância feminina ao longo de todo o período em estudo (aproximadamente 54% mulheres e 46% homens). As variações entre países são pequenas e estáveis, não indicando problemas estruturais, mas sim **tendências naturais associadas a preferências académicas e contextos nacionais**.

As diferenças por área de formação são as mais evidentes, refletindo padrões vocacionais: maior presença feminina em Educação, Saúde, Artes e Ciências Sociais; maior presença masculina em TIC, Engenharias e Indústrias. Contudo, estes padrões **não representam desequilíbrios críticos**, mas sim **tendências históricas** que se mantêm consistentes.

A distribuição por ciclos de estudo apresenta diferenças igualmente moderadas: maior presença feminina na Licenciatura e Mestrado e ligeira predominância masculina nos Doutoramentos.

Conclusões de Negócio

A) Países com maior impacto nos totais europeus

Os “países mais relevantes”, pelo seu peso nos totais europeus (França, Alemanha, Itália, Espanha), são essenciais para interpretar tendências, mas **não apresentam desequilíbrios graves**. Pequenas diferenças nos IPG destes países têm impacto na média europeia, mas sempre dentro de um intervalo estável e moderado.

Países como Suécia, Polónia ou Estónia destacam-se por valores ligeiramente mais elevados do IPG logo mais mulheres do que homens em relação aos outros países, sem representarem situações críticas. Já Alemanha e Grécia apresentam valores ligeiramente inferiores a 1, mas dentro de uma margem reduzida.

Tendências ao longo do tempo

A análise temporal revela: **Estabilidade** nas proporções de género durante toda a década, manutenção dos padrões vocacionais tradicionais por área, ausência de mudanças estruturais abruptas, crescimentos e diminuições muito suaves, dentro de variações normais.

Isto sugere que o ensino superior europeu mantém um **equilíbrio consolidado**, com pequenas diferenças que refletem preferências e estruturas educativas nacionais.

Recomendações Estratégicas

Aqui está o que faltava: **como implementar cada ação de forma concreta**, sem exagerar problemas.

Incentivar diversidade nas áreas: TIC, Engenharias e áreas tecnológicas com maior presença masculina)

Como implementar (a nível institucional ou governamental):

- Programas de orientação vocacional em escolas secundárias com workshops conduzidos por estudantes mulheres destas áreas.
- Criação de “clubs” tecnológicos mistos com atividades práticas (robótica,
- programação, cibersegurança).
- Bolsas temáticas abertas a todos, mas com campanhas de divulgação direcionadas a públicos sub-representados.
- Parcerias entre universidades e empresas tecnológicas para oferecer visitas, estágios e bootcamps acessíveis.

Equilibrar presença masculina em áreas como Educação e Saúde
Como implementar:

- Campanhas de comunicação que destaquem carreiras de sucesso masculinas nestas áreas, evitando estereótipos.
- Programas de mentoria com profissionais masculinos.
- Sessões de esclarecimento em escolas sobre diversidade nas profissões sociais e educativas.
- Incentivos a estágios em hospitais, escolas e IPSS para estudantes do secundário.

Monitorização anual contínua
Como implementar:

- Atualizar automaticamente o dashboard com dados anuais da PORDATA.
- Criar alertas simples no Power BI (ex.: variação > 1% na proporção de género por país ou área).

- Produzir relatórios anuais de duas páginas para a direção — simples e consistentes.
- Acompanhar países que mostram desvios ligeiros (ex.: Alemanha, Grécia), não por risco, mas pela sua influência estatística.

Síntese Final

A análise demonstrou que o ensino superior europeu apresenta **equilíbrio global entre géneros**, com diferenças pequenas e estáveis, mas com padrões vocacionais claros entre áreas de formação. O modelo DW/BI desenvolvido revelou-se adequado para consolidar estes dados, permitindo identificar tendências e apoiar decisões moderadas e fundamentadas, ajustadas à realidade e ao contexto académico.

Através das medidas implementadas e das recomendações propostas, é possível reforçar a diversidade, melhorar processos institucionais e monitorizar a evolução de forma rigorosa, sem dramatizar diferenças pequenas nem exagerar conclusões.

Fontes:

Apoio utilizado na construção da estrutura do Relatório: ChatGPT e Gemini
Fonte dos dados: PORDATA

Imagem do modelo conceptual: ChatGPT

Tabela da construção do Data Model no Power BI: Power BI

Gráficos do Desenvolvimento do Dashboard: Power BI

.